

Una inversión que no era física

Estudio de caso de una investigación asistida por agentes de IA

Lautaro Silva Pizzi · Manuel Racca

Proyecto final — *Investigación asistida por IA: aplicación en ondas gravitacionales* (Zalzarriaga),
FCEN-UBA, 2026

Repositorio: <https://github.com/Lautaro-Silva/Proyecto-Final-OGyAI> · versión extendida:
informe/informe.pdf

Resumen. Reconstruimos, a partir de evidencia primaria (149 *commits*, 49 registros de sesiones de Claude Code y Codex y los documentos que produjeron), cómo se investigó con agentes de IA una anomalía de la tesis de licenciatura de L. Silva Pizzi: en simulaciones, la asimetría azimutal de los muones del detector de superficie (SD) de Auger cambiaba de signo lejos del núcleo, y la del detector subterráneo (UMD) no. Tras dos semanas buscando una explicación física, la causa resultó ser un *sesgo de selección* del propio análisis. El hallazgo central del estudio es que *un subagente propuso la hipótesis correcta tres días antes de que se confirmara, pero fue descartada con un test que no podía ponerla a prueba*; la rescató una lectura independiente por otro modelo.

1. El problema

En lluvias atmosféricas inclinadas, la densidad de partículas en el plano de la lluvia no es simétrica: la región «temprana» (que el frente alcanza primero) y la «tardía» difieren. Se parametriza $\rho(\varphi) = \rho_0 (1 + A_1 \cos \varphi)$, con $A_1 > 0$ si hay exceso temprano. En simulaciones Monte Carlo (protones, SIBYLL 2.3e, 30° – 40° de cenit), el número de muones que atraviesan los tanques del SD tenía $A_1 > 0$ cerca del núcleo pero **cambiaba de signo** por encima de ~ 950 m, mientras que el UMD, enterrado a 2.3 m y con un umbral de ~ 1 GeV, se mantenía positivo. La nota interna GAP-2026-041 lo había publicado como «un rasgo genuino» de la señal del SD.

2. Qué pasó




Figura 1: Cronología por actor, desde el inicio del curso (28/08). Los puntos grandes marcan las dos veces que apareció la hipótesis de selección; las flechas, la revisión cruzada entre modelos.

Antes de los agentes. En 2025 el tesista había agregado al lector de simulaciones un requisito (HasStation) que descarta cada estación sin contraparte en el evento SD reconstruido, rotulado «corte de calidad»: si el SD no dispara, el UMD no guarda datos y esas filas parecían inútiles [41b98be, ce4e0eb].

Fase fenomenológica (28/08–10/09). Con Claude Code (Sonnet 5 y Opus 5) se construyó un archivo de contexto del proyecto (CLAUDE.md) y se revisaron las notas GAP. Se exploraron divergencia cinemática, geometría del tanque, atenuación y dispersión. El 2/09 el tesista escribió: «los datos no parecen tener bugs (podríamos chequearlo después), así que la inversión es física». Dos objeciones

suyas corrigieron errores de los agentes; con el cálculo corregido, el modelo predecía el UMD (+0.13 vs. +0.11) pero fallaba sólo en el SD (+0.19 vs. -0.10).

El casi-hallazgo (7/09). Por iniciativa propia, un subagente de Claude señaló la línea exacta: «este *HasStation(sdId)* en la línea 182 es la única compuerta de selección, sin etiquetar, de todo el pipeline [...] si el evento contiene sólo estaciones con disparo, a grandes r la región tardía pierde estaciones y las que sobreviven están fluctuadas hacia arriba». La sesión lo «descartó» con un *bootstrap* que igualaba el número de filas por bin, un test que no podía detectar un sesgo en cuáles estaciones sobreviven. El informe concluyó que la inversión «no es un artefacto del pipeline», y el prompt que Claude redactó para Codex el 10/09 dio ese descarte por «establecido».

El rescate (10/09). A los doce minutos de su primera sesión, Codex (modelo *gpt-6-astra*, «Astra»), elegido a propósito para contrastar empresas, escribió: «Hay otra selección que sí merece comprobarse: el *parquet* exige una estación SD reconstruida [...]. Eso no queda descartado por el *bootstrap* anterior, que sólo comprobó el efecto de tener distinto número de filas por bin». Esa misma tarde leyó los archivos crudos de 20 simulaciones: con todas las estaciones, $A_1 = +0.068$; exigiendo reconstrucción, -0.095 (IC 95 % de la diferencia $[-0.178, -0.145]$).

Revisión cruzada (11–24/09). Claude revisó a Astra con seis subagentes y uno adversarial («parcialmente de acuerdo»). El tesista detectó, por el conteo de filas, que un lector de Astra perdía 63 747 filas; Claude escribió un lector nuevo, que el tesista corrió, y Astra auditó el resultado de Claude. Sobre el pipeline del tesista, sin el requisito el SD muónico queda positivo y compatible con el UMD a grandes distancias (figura 2). La dirección de la tesis aprobó el resultado y pidió controles adicionales.




Figura 2: Resolución. A_1 del UMD (azul), del SD muónico sin el requisito de estación reconstruida (verde) y con él (rojo); abajo, diferencias SD–UMD con IC 95 %. Sin el requisito no hay inversión (+0.069 en lugar de -0.124 a 1200–1350 m). El UMD también está condicionado al disparo del SD y persiste una diferencia menor por debajo de 900 m. Figura del reprocesamiento (c332ab8).

3. Cómo trabajamos con los agentes

- **Memoria de proyecto:** CLAUDE.md acumuló reglas nacidas de incidentes (pedir permiso antes de git, no subir a main, no des-versionar cuadernos) y callejones sin salida; Codex la leía vía AGENTS.md.
- **Prompts estructurados** con rol de árbitro de revista, orden de lectura y preguntas numeradas; algunos los redactó un agente, lo que aportó estructura pero también propagó sesgos.




Figura 3: Flujo de trabajo: contexto compartido, dos agentes de empresas distintas que se revisan entre sí y controles humanos sobre *commits*, fusiones y cómputo pesado.

- **Subagentes en paralelo** para explorar, auditar código, revisar de forma adversarial y redactar capítulos; **revisión cruzada** entre modelos en ambas direcciones.
- **Controles humanos:** el tesista aprobó cada *commit*, fusionó los 23 *pull requests* y corrió él mismo los trabajos pesados en el servidor compartido.

4. Qué funcionó y qué no

Falla	Episodio	Quién la detectó
Test que no puede fallar	El <i>bootstrap</i> de filas «descarta» la selección (Claude, 7/09)	Otro modelo (Astra)
Resumen con pérdida y autoridad heredada	El informe omite <i>HasStation</i> ; el prompt lo da por «establecido»	Astra
Verificación que no lo era	Un chequeo imprime agreement: NO y se informa «verificado» (Claude)	Nadie, hasta este estudio
Código sin ejecutar y cambio silencioso	Lector «listo» que perdía 63 747 filas (Astra)	El tesista, por el conteo de filas
Acción destructiva	<code>git rm -cached</code> borró cuadernos del tesista (Claude)	El tesista; recuperados

Funcionó: (i) la lectura independiente por un segundo modelo; (ii) reproducir antes de extender (Astra reprodujo la figura del tesista a 10^{-9} antes de modificarla); (iii) la memoria de proyecto; (iv) las objeciones físicas y metodológicas del tesista (y, en sentido inverso, correcciones de los agentes a su física); (v) mantener humanos la fusión de cambios y el cómputo. Los errores de ingeniería más graves los detectó el humano mirando invariantes simples; el error de razonamiento más grave, otro modelo.

5. La lección y recomendaciones

La hipótesis correcta *sí* fue generada por los agentes, dos veces; el obstáculo fue la validación: un test que no podía fallar, un resumen que perdió el mecanismo y un traspaso que convirtió una duda en certeza. Irónicamente, el -0.10 que toda la fenomenología intentaba explicar era, él mismo, el número sesgado. Para el tesista, la IA «ayudó al cien por ciento»: nunca había pensado en ese requisito como una selección. Como señala Schwartz en las lecturas del curso, «dice *verificado* cuando no lo verifiqué», y conviene que un modelo revise al otro.

1. **Auditar la población antes que la física:** preguntar qué población representa cada observa-

ble.

2. **Preguntar de cada test si podría haber fallado** en caso de que la hipótesis fuera cierta.
3. **Los trasposos transmiten dudas, no veredictos.**
4. **Buscar una lectura independiente** (otro modelo o contexto limpio) que revise las premisas.
5. **Vigilar invariantes** (filas antes y después) y **exigir que el código se ejecute** sobre datos reales.

Limitaciones. Es un solo caso y todo el resultado físico es Monte Carlo (20 archivos, un primario, un modelo hadrónico); el mecanismo de la selección sigue siendo una hipótesis. El estudio lo escribió Claude (Opus 5.5) con subagentes, a partir de nuestras indicaciones; lo mitigamos exigiendo evidencia por afirmación, una verificación de 21 afirmaciones contra las fuentes (20 confirmadas) y una revisión adversarial del informe. La versión extendida, la cronología completa y toda la evidencia están en el repositorio.