

Reproducibilidad con agentes de IA aplicada al efecto Leidenfrost

Proyecto final - verificación, reproducción independiente y trazabilidad de un análisis experimental

Nikita Kacuk y Mateo Villani

Trabajo realizado mediante el uso del asistente de IA Claude.

Pregunta del proyecto

Partimos de un experimento previamente realizado sobre cilindros de cobre sumergidos en nitrógeno líquido. El objetivo fue estudiar qué cambia cuando un agente de IA trabaja con **el resultado ya terminado** frente a cuando debe **reconstruirlo desde las fuentes primarias**, y qué evidencia hace falta para poder defender sus resultados.

Método 1 Verificación con acceso al informe	Método 2 Reproducción independiente
El agente recibe el informe original terminado. Recalcula valores, revisa coherencia interna y busca inconsistencias.	El agente no recibe el informe. Trabaja con CSV, guías y parámetros experimentales para reconstruir el análisis.
¿Puede auditar un resultado conocido?	¿Puede recuperar el resultado sin conocer la respuesta?

Ver un resultado terminado permite verificarlo, pero no demuestra que sea reproducible. La prueba más exigente es reconstruirlo desde las fuentes primarias sin conocer de antemano la respuesta.

Caso de estudio

El experimento estudia el enfriamiento de cilindros de cobre en nitrógeno líquido. A alta temperatura se forma una película de vapor que reduce la transferencia de calor; al enfriarse el cilindro, esa película colapsa. Se analizaron $T(t)$, el tiempo crítico t_c , Q/A , la relación con $p=m/A$, la balanza y el efecto de modificar la superficie.

Dos formas distintas de trabajar con el mismo problema

Verificación con acceso al informe

En este método Claude recibió el informe experimental ya terminado. Su tarea no fue rehacer el experimento desde los CSV, sino **auditar el producto existente**: reconstruir qué ecuaciones y valores sustentaban las conclusiones, recalcular cantidades que podían comprobarse con la información publicada y revisar si texto, números, figuras y argumentos eran internamente consistentes.

Este procedimiento permitió revisar las geometrías y la relación $p=m/A$, examinar los tiempos críticos reportados y detectar dos puntos importantes: la mezcla entre Θ_E y Θ_D en el tratamiento del calor específico, y la afirmación de que dos pendientes de la balanza eran compatibles aun cuando las incertidumbres publicadas no respaldaban esa conclusión.

Reproducción independiente desde datos

En el segundo método el informe original fue excluido como input. Claude recibió los CSV experimentales, las guías y los parámetros necesarios, y tuvo que reconstruir el análisis: calibración, $T(t)$, detección de t_c , Q/A , análisis de balanza, figuras y extensiones. Solo después se compararon esos resultados con el informe.

La diferencia es metodológica: el primer método pregunta si un resultado conocido **se sostiene**; el segundo pregunta si ese resultado **puede recuperarse sin conocerlo de antemano**. Por eso no esperamos que ambos agentes produzcan las mismas figuras: uno audita material existente y el otro genera resultados nuevos desde los datos.


Provenance y checks

La reproducción independiente registra además el origen de los resultados en **provenance.json** y ejecuta **checks.py**. Así se puede rastrear qué archivo y qué procedimiento producen cada cantidad, distinguir valores medidos, supuestos y resultados derivados, y comprobar que el pipeline puede volver a ejecutarse de forma consistente.

Reproducir un valor no consiste únicamente en obtener un número parecido al original: debe poder rastrearse qué datos y procedimientos lo produjeron y qué verificaciones respaldan el resultado.

Resultado auditado vs. resultado reconstruido: temperatura y t_c

La figura del informe funciona como **resultado auditado** en el método con acceso al documento. En la reproducción independiente, la curva se genera nuevamente desde los CSV. La comparación se realiza recién al final.



Cilindro	Informe original t_c	Reconstrucción t_c	Diferencia
A	302.1 ± 0.8 s	294.9 s*	2.4 %
B	129.5 ± 0.8 s	123.7 s*	4.5 %
C	172.6 ± 0.8 s	168.3 s*	2.5 %


* La reproducción desde datos no reportó una incertidumbre $\sigma(t_c)$ independiente. Sí verificó que el instante detectado no cambiara al variar los parámetros de suavizado considerados, pero esa sensibilidad nula no sustituye una incertidumbre experimental.

Resultado central: la reproducción independiente recuperó los tres t_c con diferencias de aproximadamente 2.4-4.5 % y el mismo orden $t_B < t_C < t_A$. Como no se obtuvo $\sigma(t_c)$ para la reconstrucción, no corresponde afirmar compatibilidad estadística entre ambos conjuntos.

No todo coincidió. El informe ubica la transición aproximadamente entre 111 y 119 K, mientras que el criterio automático de la reproducción la sitúa alrededor de 102-105 K. Los tiempos permanecen próximos: la discrepancia está asociada al criterio usado para asignar una temperatura puntual dentro de una transición rápida.

Balanza: una auditoría que conduce a una nueva interpretación

Este caso muestra con claridad la complementariedad entre los métodos. El primero identifica una inconsistencia en una afirmación del informe; el segundo vuelve a la serie temporal completa para estudiar qué puede estar ocurriendo.



Qué detectó la verificación

El informe reportaba pendientes cercanas a -0.0952 g/s y -0.131 g/s y las describía como compatibles. Al usar literalmente las incertidumbres publicadas, la verificación encontró una separación cercana a 12σ . El aporte de este método fue señalar que la conclusión escrita no se seguía de los números mostrados.


Qué agregó la reproducción desde los datos

La serie completa permite distinguir mejor la dinámica posterior a la inmersión. La cola tardía recupera una tasa de evaporación cercana al fondo inicial, mientras que inmediatamente después del experimento todavía existe un aporte térmico residual del cilindro. Modelar ese aporte como una relajación temporal ayuda a explicar por qué una pendiente global de la tercera etapa puede diferir del fondo.

La verificación responde «¿la afirmación está respaldada?». La reproducción desde datos permite avanzar hacia «¿qué estructura de la medición puede explicar la diferencia?».

Q/A frente a ΔT : auditar una figura y reconstruir el análisis

El gráfico de Q/A frente a la diferencia de temperatura ya estaba presente en el informe y, por lo tanto, formó parte del material auditado por el método de verificación. La reproducción independiente vuelve a calcular Q/A desde los CSV y luego lo relaciona explícitamente con los regímenes de ebullición de la guía.



La diferencia importante no es que el segundo método haya «inventado» Q/A vs. ΔT . El observable ya estaba en el trabajo original. Lo que cambia es el nivel de acceso al proceso: la verificación puede auditar la figura y las ecuaciones que la sustentan; la reproducción obtiene nuevamente la curva desde los datos y puede extender su interpretación.

Conclusiones

- La reproducción independiente recuperó los tiempos críticos con diferencias de aproximadamente 2.4-4.5 % y la relación entre $p=m/A$ y t_c .
- El informe original sí asigna ± 0.8 s a cada t_c ; la reproducción no generó una $\sigma(t_c)$ equivalente, por lo que la comparación debe presentarse como cercanía porcentual y no como compatibilidad estadística.
- La verificación con informe fue útil para detectar inconsistencias internas; volver a los datos permitió comprobar resultados y explorar explicaciones adicionales.
- Provenance y checks hacen que los resultados sean rastreables, repetibles y defendibles.

La reproducibilidad no consiste únicamente en obtener el mismo número: consiste en poder explicar de dónde salió, cómo volver a obtenerlo y qué evidencia permite confiar en él.