

¿Por qué falló la estimación de β a INL alto?

Re-estudio de `beta_pred_formula()` en el rango $\text{INL} \in [10^{-3}, 2 \times 10^{-1}]$

Walter Quiñonez

Reporte generado con Claude Code · 12 de septiembre de 2026

*Al correr el experimento de `prompt.txt` (`a_pot=5.85`, $\text{INL} \approx 2 \times 10^{-1}$, `batch_number=1`), la búsqueda automática de β eligió $\beta = 1389$ mientras la fórmula analítica predecía 86.8 – un factor $16\times$, el máximo que permite la red de seguridad de expansión. Se pidió re-estudiar la estimación de β para el rango de INL 2×10^{-1} a 10^{-3} . **Conclusión principal:** la fórmula NO está rota en ese rango –evaluada contra las 30 combinaciones de fuerza bruta disponibles hoy da mediana de error $0.94\times$ y peor caso $1.26\times$, y reajustarla con más datos no mejora nada–. La causa real es otra: todo el ground truth (y por lo tanto la fórmula) fue generado con `batch_number=32`, una variable que ni la fórmula ni la búsqueda automática modelan. Un chequeo empírico barato confirma que a `batch_number=1` el β óptimo real es varias veces más grande que a `batch_number=32`, para el mismo INL .*

Índice

1. Contexto: qué pasó y qué se pidió	1
2. Primera hipótesis: ¿la fórmula falla en este rango de INL?	1
3. La causa real: <code>batch_number</code> , una variable no modelada	2
3.1. Chequeo empírico	3
4. Recomendaciones	4
5. Limitaciones	4

1. Contexto: qué pasó y qué se pidió

Corriendo `Crossbar_train_experimento_beta_por_capa.py` con los parámetros de `prompt.txt` (`a_pot=a_dep=5.85`, `pulsos=50`, `concavidad pos/neg`, `batch_number=1`, `optimize_beta=True`), `search_best_beta_mejorado` centró su grilla en $\beta_{\text{pred}} = 86.8$ (fórmula analítica de `formula_beta_optimo_propuesta/`), pero el óptimo empírico de la búsqueda se fue corriendo hacia arriba en cada expansión hasta $\beta = 1389$ (factor $16\times = 4 \times 4\times$ el margen, el techo con `max_expansiones=2`), sin encontrar un pico real. Esto se interpretó como que “la estimación estaba fallando” para este INL , y se pidió re-estudiarla incluyendo el rango $\text{INL} \in [10^{-3}, 2 \times 10^{-1}]$.

2. Primera hipótesis: ¿la fórmula falla en este rango de INL?

El ground truth de fuerza bruta en `data_beta_grid_search_SP/` ya cubre justo este rango y más: 10 valores de INL nominal (2×10^{-1} hasta 4.82×10^{-6}) $\times$ 3 cantidades de pulsos = 30 combinaciones, cada una con 20 series $\times$ 5 folds $\times$ 100 épocas reales. La fórmula en producción (`beta_pred_formula`, coeficientes ajustados sobre 18 de esas 30 curvas) se re-evaluó -sin volver a entrenar nada, el Monte Carlo de σ_W /paso_medio tarda milisegundos- restringida a las 15 combinaciones con INL en $[10^{-3}, 2 \times 10^{-1}]$, y se comparó contra dos reajustes alternativos validados por leave-one-out cross-validation (para no premiar sobreajuste):

Modelo	mediana(ratio)	rango(ratio)	RMSE(log ratio)
v2 producción (sin reajustar)	0.940	[0.733, 1.264]	0.172
Reajuste con 30 combos (LOOCV)	0.963	[0.729, 1.500]	0.194
Reajuste solo del rango pedido (LOOCV)	0.971	[0.724, 1.473]	0.204

Cuadro 1: Error de predicción ($\beta_{\text{pred}}/\beta_{\text{óptimo real}}$), los 3 modelos evaluados SOLO en las 15 combinaciones $\text{INL} \in [10^{-3}, 2 \times 10^{-1}]$. Script: `reestimar_formula_beta_optimo.py`.

La fórmula que ya está en producción es, de las tres, la que **mejor generaliza** en este rango -ni agregar las 12 combinaciones nuevas ni especializar el ajuste al rango mejora el error-. Ver Figura 1. Esto descarta la hipótesis de que la fórmula esté “rota” para INL alto: para $\beta_{\text{pred}} = 86.8$ contra el óptimo real de $\beta = 100$ ($\text{INL} = 2 \times 10^{-1}$, $p=50$, `batch_number=32`) el ratio es 0.868, dentro de lo esperado.

3. La causa real: batch_number, una variable no modelada

Si la fórmula predice bien para `batch_number=32` (el único régimen con ground truth), ¿por qué la búsqueda automática -corriendo con `batch_number=1`, como pedía `prompt.txt`- se fue tan lejos de esa predicción? Hipótesis: `batch_number` determina cuántas actualizaciones de pulso ocurren por época (`batch_number` pasos, cada uno sobre una fracción del dataset), y el β óptimo depende fuertemente de cuántas actualizaciones totales va a recibir el crossbar durante el entrenamiento -algo que ni la fórmula (funciones solo de la curva P/D) ni el ground truth (siempre corrido a `batch_number=32`) contemplan.

3.1. Chequeo empírico

Para confirmarlo sin correr una fuerza bruta completa, se entrenó el mismo caso ($\text{INL} = 2 \times 10^{-1}$, $p=50$, $a_{\text{pot}}=5.85$) con `batch_number=1`, 100 épocas, 5 folds, pero con β **fijo** (sin búsqueda) en 3 valores nuevos (50, 100, 300), más el $\beta = 1389$ ya entrenado por la búsqueda automática (`MLP_test_SP/`):

Confirmado: a `batch_number=1` un β mucho más grande de verdad da mejor accuracy -no fue un artefacto de la búsqueda corta (8 épocas) ni de la expansión automática-. La Figura 2 contrasta esta curva con el ground truth completo a `batch_number=32` para el mismo INL: a `bn=32` el óptimo es un pico agudo en $\beta \approx 100$ (accuracy ≈ 0.85) que colapsa rápido para β mayores; a `bn=1` la curva sube lento y sigue subiendo más allá de $\beta = 1389$, sin haber encontrado su pico.




Figura 1: β_{pred} de los 3 modelos vs. $\beta_{\text{óptimo}}$ real (fuerza bruta, batch_number=32), restringido a $\text{INL} \in [10^{-3}, 2 \times 10^{-1}]$ (15 combos). Los tres caen casi sobre la identidad.

β (fijo)	accuracy final (media, 5 folds)
50	0.6313
100	0.6356
300	0.6505
1389	0.7004

Cuadro 2: batch_number=1, 100 épocas, 5 folds, $\text{INL}=2 \times 10^{-1}$, $p=50$. Accuracy sigue subiendo monótonamente hasta $\beta = 1389$ -no se llegó todavía al pico real-.




Figura 2: Accuracy vs. β para el mismo INL/pulsos, a **batch_number=32** (ground truth completo) vs. **batch_number=1** (chequeo barato, 4 puntos). El óptimo se desplaza más de un orden de magnitud.

4. Recomendaciones

1. **No hace falta re-derivar `beta_pred_formula`:** ya generaliza bien ($\pm 26\text{-}30\%$) en todo el rango INL $[10^{-3}, 2 \times 10^{-1}]$ para el régimen en el que hay ground truth (`batch_number=32`). Reajustarla con más datos no ayuda (Sección 2).
2. **`batch_number` lejos de 32 invalida el centro de la grilla:** cuando se corra con un `batch_number` muy distinto al del ground truth (como `batch_number=1` en `prompt.txt`), tratar la predicción de la fórmula solo como un punto de partida, no como un resultado confiable -la red de seguridad de `search_best_beta_mejorado` (`margen`, `max_expansiones`) es la que sostiene la precisión en ese caso, y puede necesitar más margen del default (el chequeo de este informe ni siquiera llegó al pico real con $16\times$ de margen).
3. **Corto plazo, sin código nuevo:** si se sabe de antemano que `batch_number` será chico, llamar a `search_best_beta_mejorado` con `margen` y/o `max_expansiones` más generosos (ya son parámetros expuestos, no hace falta tocar código) para no cortar la expansión antes de encontrar el pico real.
4. **Mediano plazo:** generar ground truth de fuerza bruta a `batch_number` chico (análogo a `data_beta_grid_search_SP/` pero variando `batch_number` en vez de INL) permitiría ajustar una fórmula que incluya el número total de actualizaciones (`epochs` $\times$ `batch_number`) como variable explícita -queda fuera del alcance de este informe por el costo de cómputo (cada combo de fuerza bruta completo tarda horas).

5. Limitaciones

- El chequeo de `batch_number=1` usa 1 serie y 4 valores de β (no 20 series y 40 valores como el ground truth completo) -suficiente para confirmar la dirección y magnitud del efecto, no para fijar un $\beta_{\text{óptimo}}$ preciso a `batch_number=1`: la curva de la Figura 2 ni siquiera encontró su pico.
- Solo se probó un combo (INL= 2×10^{-1} , $p=50$); no se verificó si la magnitud del efecto de `batch_number` es la misma en otros INL del rango pedido.
- El re-ajuste de la fórmula (Sección 2) sigue sin optimizar β distintos por capa, ni contempla otras arquitecturas o ratios Gmax/Gmin (misma limitación que las versiones anteriores).

Scripts y datos: `reestimar_formula_beta_optimo.py` (re-ajuste y LOOCV, no entrena nada) y `chequeo_batch_number/` (los 3 entrenamientos reales a beta fijo, sus `.npz/.json` y el script de la Figura 2), ambos en esta misma carpeta.