

Fórmula de β óptimo

Extensión a las 30 curvas de INL disponibles

Walter Quiñonez

Reporte generado con Claude Code · 7 de septiembre de 2026

*Extiende `reconstruccion_beta_optimo_18curvas/` (6 INL $\times$ 3 pulsos, $R^2 = 0.938$) a las **30 curvas** que hay ahora en `data_beta_grid_search_SP/` (10 INL nominal $\times$ 3 pulsos). Mismo método exacto, sin reentrenar nada. **Resumen ejecutivo:** la fórmula ya encontrada con 18 curvas se reconfirma casi sin cambios al triplicar-y-medio el rango de INL cubierto (coeficientes prácticamente idénticos, $R^2 = 0.938 \rightarrow 0.930$). Además, 30 de 30 curvas alcanzan $\geq 99\%$ de su accuracy pico usando el β que predice la fórmula, sin ninguna búsqueda —validado contra la grilla real de 40 β por curva.*

Índice

1. Método	1
2. La ecuación de Prezioso/LeCun literal sigue sin explicar esto	1
3. La fórmula final	2
4. Validación práctica: ¿sirve para saltarse la búsqueda?	2
5. Errores por curva —dónde falla más la fórmula	3
6. Conexión con los hallazgos de distribución de logits/softmax	4
7. Limitaciones (heredadas del reporte de 18 curvas, sin resolver aún)	5
8. Recomendación (sin cambios respecto del reporte de 18 curvas, ahora con más evidencia)	5
9. Archivos generados	5

1. Método

- **Datos:** las 30 carpetas `beta_grid_search_SP_INL_*` de `data_beta_grid_search_SP/`, usando la corrida real $\beta = 1$ de cada una (determinista, sin ruido).
- **σ_I candidatas** (3 fuentes, igual que el reporte de 18 curvas): (1) `sigma_I_mc_corregido` —Monte Carlo con `G0_initialization` real (pool combinado `potUdep`) y voltajes muestreados de los píxeles reales de MNIST (frecuencia real); (2) `sigma_I_real_ep1` —corriente real

reconstruida en la 1ª época guardada; (3) `sigma_I_real_epLast` —corriente real reconstruida en la última época (convergada).

- **β empírico:** el óptimo de la grilla de 40 β (`resumen_por_INL/resumen_optimos.csv`).
- **Ajuste:** regresión log-log, $\log \beta = \text{intercept} + a \log \sigma_I + b \log(\text{paso_medio_pot})$.

Scripts: `reconstruir_corrientes_30curvas.py` (genera `resultados_30curvas.csv`),
`probar_prezioso_y_regresiones_30curvas.py` (ajusta los modelos),
`evaluar_formula_en_grilla_completa.py` (valida contra la grilla real).

2. La ecuación de Prezioso/LeCun literal sigue sin explicar esto




Figura 1: R^2 de los 6 modelos probados (3 fuentes de $\sigma_I \times$ solo/combinado con `paso_medio`), 30 curvas. La línea punteada es Prezioso literal (exponente -1 fijo).

Igual que con 18 curvas: fijar el exponente en -1 ($\beta = \kappa/\sigma_I$, la forma literal citada por Prezioso et al. de LeCun et al.) da $R^2 = 0.276$ con la mejor fuente de σ_I (MC corregido) —el κ implicado varía $5.1\times$ entre curvas. Con las otras dos fuentes de σ_I (corriente real) el ajuste literal es directamente malo o negativo ($R^2 = -0.11$ y $R^2 = -0.02$).

Dejando el exponente **libre** y agregando `paso_medio_pot` como segunda variable, el modelo con `sigma_I_mc_corregido` es, por lejos, el mejor de los 6 probados: $R^2 = 0.930$, muy por encima de cualquier variante con corriente real ($R^2 \leq 0.46$) —igual que con 18 curvas, usar la corriente ya entrenada (que depende circularmente del propio β) empeora la predicción en vez de mejorarla.

3. La fórmula final

$$\beta_{\text{óptimo}} \approx 1.41 \times 10^{-8} \cdot \sigma_{I,MC}^{-3.00} \cdot \text{paso_medio}^{-0.62} \quad (1)$$

con $\sigma_{I,MC}$ y `paso_medio` en Siemens. $R^2 = 0.930$ sobre las 30 curvas (ajuste log-log).




Figura 2: β predicho por la ecuación final vs. β óptimo empírico, 30 curvas, $R^2 = 0.930$.

	18 curvas (reporte previo)	30 curvas (este reporte)
exponente de $\sigma_{I,MC}$	-3.06	-3.00
exponente de paso_medio	-0.61	-0.62
R^2	0.938	0.930

Cuadro 1: Comparación de coeficientes: 18 vs. 30 curvas.

Los coeficientes son **prácticamente idénticos** al agregar 12 curvas nuevas (4 valores de INL que no formaban parte del ajuste original, incluyendo **5e-2** que cae justo en la zona de transición). Señal fuerte de que la fórmula generaliza —no es un sobreajuste a las 6 curvas originales.

4. Validación práctica: ¿sirve para saltarse la búsqueda?

Para cada curva: se calculó β_{pred} con la Ec. 1 (sin entrenar nada), se buscó el punto de la grilla real de 40 β más cercano, y se comparó su accuracy contra el pico real de esa curva completa —no una aproximación de meseta simétrica como en el reporte de 18 curvas, sino la grilla real.

Resultado: 30 de 30 curvas alcanzan ≥ 99 % de su accuracy pico (media 99.95 %, mínimo 99.38 % en $\text{INL}=4.82\text{e-}6$, $p=50$) usando β_{pred} sin ninguna búsqueda —a pesar de que el error de β_{pred} contra $\beta_{\text{óptimo}}$ real llega hasta ± 32 % en algunas curvas (Sección 5). Tiene sentido: las curvas accuracy-vs- β tienen un pico ancho (meseta), así que un error de 20–30 % en β no cuesta casi nada de accuracy real.




Figura 3: Accuracy en β_{pred} como % del pico real de cada curva (grilla completa de 40 β), 30 curvas ordenadas.

5. Errores por curva —dónde falla más la fórmula

Error absoluto porcentual: **media=11.5 %**, **mediana=11.7 %**, **máximo=32.5 %** sobre las 30 curvas. Los peores casos se concentran en $p = 50$ (curva P/D más gruesa, `paso_medio_pot` más grande —el término que más castiga la predicción) y en `INL=2e-1` (la curva más no lineal, con la dinámica de entrenamiento más inestable, ver `analisis_distribucion_softmax_INL_2e-1_comparacion_p/` —tiene sentido que sea también donde la fórmula, que solo mira la curva P/D antes de entrenar, tenga más dificultad).

6. Conexión con los hallazgos de distribución de logits/softmax

Esta fórmula predice β óptimo **antes de entrenar**, a partir solo de la curva P/D. Es distinta —y complementaria— del hallazgo de `analisis_distribucion_softmax_INL_2e-1_comparacion_p/`: ahí se vio que el desvío estándar de los logits **ya entrenados** ($\beta \cdot I$, modelo convergido) en el β

curva	β empírico	β predicho	error
INL=2e-1, p=100	100	132.5	+ 32.5 %
INL=1e-3, p=50	400	300.0	- 25.0 %
INL=5e-2, p=200	600	459.8	-23.4 %
INL=1e-5, p=50	250	303.5	+21.4 %
INL=4.82e-6, p=50	250	303.5	+21.4 %
INL=1e-2, p=100	350	421.0	+20.3 %
(24 curvas restantes: entre -15 % y +18 %)			

Cuadro 2: Peores errores de predicción, 30 curvas. Tabla completa: `resultados_prezioso_30curvas.csv`.

óptimo cae en una banda angosta *dentro de un mismo INL* (1.8–2.7 para INL=2e-1, 3.5–6.4 para INL=1e-2) pero esa banda **no es universal entre INL distintos**.

Esto es coherente con el resultado de esta sección: el exponente de σ_I en la fórmula es -3 , no -1 (Prezioso literal asumiría $\beta \cdot \sigma_I \approx \kappa$ constante) —el propio dato ya venía diciendo que la relación entre β óptimo y la dispersión de corriente NO es tan simple. La fórmula de esta sección usa σ_I de **inicialización** con un exponente fuerte (-3) para compensar exactamente esa no-linealidad; el hallazgo de logits post-entrenamiento la confirma desde el otro extremo (después de entrenar, la “banda sana” de dispersión de logits también depende del INL, no es una constante única).

7. Limitaciones (heredadas del reporte de 18 curvas, sin resolver aún)

- **N fijo.** Las 30 curvas comparten $N = 784$ (fan-in de MNIST) —el exponente de N en la ecuación teórica ($N^{-1/2}$) sigue sin poder testearse con esta data.
- **Un solo dataset.** Fashion-MNIST ya está disponible (`X_train_mnist_fashion.npy`) pero no se usó todavía.
- **Grilla de β de 40 puntos, espaciados de a 50.** El β óptimo empírico contra el que se ajusta tiene ese error de resolución.
- **Zona de transición INL incompleta.** 7e-2, 1e-1, 1.3e-1, 1.6e-1 (jobs ya generados, `train_job_INL_7e-2_p_50.sh` y afines, pero aún no corridos/bajados) llenarían el hueco entre 5e-2 y 2e-1.
- **Ajuste in-sample.** Los R^2 se calculan sobre las mismas 30 curvas usadas para ajustar los coeficientes. La estabilidad de los coeficientes al pasar de 18→30 curvas (Sección 3) es la mejor evidencia disponible de que no es sobreajuste, pero no reemplaza una validación real con datos no usados en el ajuste.

8. Recomendación (sin cambios respecto del reporte de 18 curvas, ahora con más evidencia)

Igual que antes: **no reemplazar `search_best_beta()` por la fórmula en modo “un solo paso, sin verificar”**. Usarla como **pre-filtro barato**: calcular β_{pred} (sin entrenar nada) y correr

`search_best_beta()` en una ventana angosta alrededor ($\beta_{\text{pred}} \times [0.5, 2]$, 5–7 puntos) en vez de la grilla completa (1–1950, 40 puntos) —ahorro de cómputo de $\sim 5\text{--}8\times$ sin perder la garantía de una búsqueda real. La evidencia de este reporte (30/30 curvas $\geq 99\%$ del pico, con la grilla REAL) es más fuerte que la del reporte de 18 curvas, pero sigue siendo evidencia sobre un único régimen (SP, $N = 784$, MNIST) —no una garantía general.

9. Archivos generados

- `reconstruir_corrientes_30curvas.py` → `resultados_30curvas.csv`,
`trayectorias_std_30curvas.png`, `comparacion_sigma_fuentes_30curvas.png`.
- `probar_prezioso_y_regresiones_30curvas.py` → `resultados_prezioso_30curvas.csv`,
`coeficientes_todos_los_modelos_30curvas.csv`, `prezioso_literal_vs_empirico_30curvas.png`,
`comparacion_R2_todos_los_modelos_30curvas.png`, `ecuacion_final_vs_empirico_30curvas.png`.
- `evaluar_formula_en_grilla_completa.py` → `evaluacion_formula_en_grilla.csv`,
`formula_vs_grilla_real.png`.
- `reporte_formula_beta_optimo_30curvas.md` —versión Markdown de este mismo reporte.