

¿Sigue funcionando `search_best_beta_mejorado` fuera de su rango de conductancia calibrado?

Validación de la búsqueda de beta y de la fórmula analítica para ratios

$$G_{\text{máx}}/G_{\text{mín}} \in \{2, 20, 100\}$$

Walter Quiñonez

Reporte generado con Claude Code · 10 de septiembre de 2026

MemDNNMejorado.search_best_beta() (*mejora_search_best_beta()*) y la fórmula analítica que centra su grilla (*beta_pred_formula*) se calibraron y validaron con el rango de conductancia fijo de todo el proyecto ($R_{\text{low}} = 1000\Omega$, $R_{\text{high}} = 10000\Omega \Rightarrow \text{ratio } G_{\text{máx}}/G_{\text{mín}} = 10$). Esta corrida prueba si siguen funcionando cuando ese rango cambia ($\text{ratio} \in \{2, 20, 100\}$, con INL de la curva P/D casi constante para aislar el efecto del rango de conductancia). Conclusión: **sí** — el regret del beta elegido se mantiene por debajo de 0.52pp en los tres ratios, incluso en $\text{ratio}=2$, donde la fórmula subestima el beta óptimo real por un factor $\sim 5.9\times$ y la red de seguridad (expansión automática de la grilla) es la que sostiene la precisión.

Índice

1. Pregunta y metodología	1
2. Resultados	2
2.1. Grillas de referencia	2
2.2. Búsqueda mejorada: predicción de la fórmula vs. beta elegido	2
2.3. En contexto: los 4 ratios probados hasta hoy	2
3. Conclusión	2
4. Limitaciones	3

1. Pregunta y metodología

Para cada ratio $G_{\text{máx}}/G_{\text{mín}} \in \{2, 20, 100\}$ ($R_{\text{low}} = 1000\Omega$ fijo, $R_{\text{high}} = R_{\text{low}} \cdot \text{ratio}$; $\text{ratio}=10$ ya está validado en `mejora_search_best_beta/`, no se repite acá):

- Referencia** (independiente de la fórmula): grilla ancha y fija de 10 betas log-espaciados en $[20, 8000]$, evaluada con el protocolo mínimo validado en `analisis_epochs_series_minimos/` (Fase 3: `series=8`, `k_folds=3`, `epochs=8`). El beta con mayor accuracy media de esa grilla es el “óptimo real” de referencia para ese ratio.
- Búsqueda mejorada**: se corre `search_best_beta` 3 veces con semillas distintas, y se compara el beta elegido contra la referencia ($\text{regret} = \text{accuracy de la referencia en su óptimo} - \text{accuracy}$

de la referencia en el punto de grilla más cercano al beta elegido).

INL_{pot} se mantuvo prácticamente constante entre ratios (0.0101 para ratio=20 y ratio=100; documentado entre 0.0065 y 0.0101 para ratio 2..100 en el script), para aislar el efecto del rango de conductancia del efecto de no linealidad.

Código: `estudiar_rangos_conductancia.py` (no modifica ningún archivo original del proyecto). Datos completos, verificables: `resultados_rangos_conductancia.json` y `referencia_ratio{2,20,100}.json` en esta misma carpeta.

2. Resultados

2.1. Grillas de referencia

Ratio $G_{\max}/G_{\min}$	$\beta_{\text{óptimo}}$ referencia	acc. óptima referencia
2	557.98	0.9074
20	286.75	0.9078
100	286.75	0.9079

Cuadro 1: Óptimo de la grilla ancha y fija de 10 betas (log-espaciados en [20,8000]), protocolo mínimo. Ratio 20 y 100 caen en el mismo punto de esa grilla (resolución de la grilla, no necesariamente el mismo óptimo continuo); el accuracy en ese punto es prácticamente idéntico entre ambos.

El óptimo real se corre hacia betas más chicos a medida que aumenta el ratio (más rango de conductancia disponible por bit de resolución), consistente con lo esperado.

2.2. Búsqueda mejorada: predicción de la fórmula vs. beta elegido

Ratio	β_{pred} (fórmula)	factor vs. real	expansiones	regret medio	regret peor caso
2	3294.9	5.91×	1 (las 3 corridas)	0.09 pp	0.27 pp
20	315.6	1.10×	0	0.15 pp	0.23 pp
100	271.4	0.95×	0	0.17 pp	0.51 pp

Cuadro 2: 3 repeticiones (semillas nuevas) por ratio. “factor vs. real” = $\beta_{\text{pred}}(\text{fórmula})/\beta_{\text{óptimo referencia}}$. Detalle de las 9 corridas en `resultados_rangos_conductancia.json`.

Ratio=2 es el caso interesante: la fórmula (ajustada y validada solo en ratio=10) subestima el beta óptimo por casi 6× — la extrapolación fuera de su rango de calibración falla claramente acá, mucho más que en ratio=20 o 100 (factores 1.10× y 0.95×, dentro del error ya documentado de la fórmula en `formula_beta_optimo_propuesta/`). Sin embargo, la red de seguridad de `search_best_beta_mejorado` (expansión automática del margen cuando el óptimo empírico cae en el borde de la grilla angosta) se activó en las 3 corridas de ratio=2, y el beta finalmente elegido (653.8 u 823.7) quedó igual de cerca del óptimo real (557.98) que en los ratios donde la fórmula no falló: regret peor caso 0.27pp, comparable a los otros ratios. El costo de esa expansión es evaluar el doble de puntos de grilla: las búsquedas de ratio=2 tardaron $\approx 442s$ contra $\approx 235\text{--}248s$ de ratio=20/100 sin expansión.

Ratio $G_{\text{máx}}/G_{\text{mín}}$	regret peor caso	fuelle
2 (este reporte)	0.27 pp	resultados_rangos_conductancia.json
10 (calibración original)	0.45 pp	mejora_search_best_beta/resultados_validacion.json
20 (este reporte)	0.23 pp	resultados_rangos_conductancia.json
100 (este reporte)	0.51 pp	resultados_rangos_conductancia.json

Cuadro 3: El dato de ratio=10 viene de un protocolo de referencia distinto (ground truth de 100 épocas/20 series/5 folds sobre 2 combos INL, no la grilla mínima de 10 puntos usada acá) – no es estrictamente comparable número a número, pero da la misma conclusión cualitativa: regret peor caso siempre por debajo del umbral de 1pp que analisis_epochs_series_minimos/ estableció como aceptable.

2.3. En contexto: los 4 ratios probados hasta hoy

3. Conclusión

La búsqueda mejorada de beta **sigue funcionando bien fuera del rango de conductancia con el que se calibró** (ratio=10), en los tres ratios adicionales probados (2, 20, 100): el regret del beta elegido contra la referencia nunca superó 0.51pp, muy por debajo del umbral de 1pp ya establecido como aceptable en este proyecto. Esto se sostiene incluso cuando la fórmula analítica que centra la grilla de búsqueda extrapola mal (ratio=2, factor $\sim 5.9\times$): el mecanismo de expansión automática del margen compensa el error de la fórmula al costo de duplicar el número de puntos de grilla evaluados (y por lo tanto el tiempo de búsqueda) en ese régimen.

4. Limitaciones

- La referencia usa una grilla fija de solo 10 betas log-espaciados (protocolo mínimo, no el ground truth completo de `data_beta_grid_search_SP/`), igual que se documenta en `estudiar_rangos_conductancia.py`; es suficiente para el protocolo ya validado pero no un ground truth perfecto.
- Ratio 20 y 100 dieron el mismo punto óptimo de referencia (286.75) – posible efecto de la resolución de la grilla de referencia (10 puntos entre 20 y 8000) más que de que el óptimo continuo sea idéntico.
- El dato de ratio=10 usado como contexto viene de un protocolo distinto (ver tabla de la sección anterior), no es una corrida nueva con el mismo protocolo que ratio=2/20/100.
- Solo 3 repeticiones por ratio (igual que se especificó en el script), no las 5 usadas en la validación original de `mejora_search_best_beta/`.
- Sigue sin optimizarse un beta distinto por capa (mismo alcance que el resto del proyecto).